

Cahier de Charge – Projet IA Générative

Intitulé du projet

Conception et implémentation d'un système RAG (Retrieval-Augmented Generation)

Contexte

Dans le cadre du module d'**IA Générative**, les étudiants sont amenés à concevoir un système intelligent capable de répondre à des questions en s'appuyant sur une base de connaissances spécifique.

Le projet repose sur le concept de **RAG (Retrieval-Augmented Generation)**, qui combine :

- la **recherche d'information (retrieval)**
 - la **génération de texte via un LLM (Large Language Model)**
-

Objectifs pédagogiques

À la fin de ce projet, l'étudiant devra être capable de :

- Comprendre le fonctionnement d'un système RAG
 - Manipuler des embeddings et une base vectorielle
 - Interagir avec un modèle de langage (LLM)
 - Concevoir une pipeline complète de traitement de données
 - (Option avancée) Implémenter des systèmes agentiques ou des architectures modulaires
-

Description générale du projet

Chaque groupe devra développer une application permettant de :

1. Charger un corpus de documents (PDF, texte, pages web...)
2. Transformer ces documents en embeddings
3. Stocker les embeddings dans une base vectorielle
4. Permettre à un utilisateur de poser des questions
5. Générer des réponses pertinentes basées sur le corpus

Options du projet

Les étudiants doivent choisir **UNE seule option** parmi les suivantes :

Option 1 : RAG Simple (Obligatoire – Niveau Débutant)

Implémenter un pipeline RAG basique :

- Chargement de documents
- Chunking du texte
- Création d'embeddings
- Stockage dans une base vectorielle (ex: FAISS, ChromaDB, Qdrant)
- Recherche des documents pertinents
- Génération de réponse avec un LLM

Objectif : Comprendre le pipeline RAG de bout en bout

Option 2 : RAG Amélioré (Intermédiaire)

Ajouter des améliorations au RAG simple :

- Re-ranking des résultats
- Gestion du contexte (prompt engineering)
- Mémoire de conversation
- Interface utilisateur simple (Streamlit / Gradio)

Objectif : Améliorer la qualité des réponses

Option 3 : Agentic RAG (Avancé)

Implémenter un système avec agents :

- Utilisation d'un agent (ex: LangChain Agent, CrewAI...)
- Capacité à décider :
 - quand faire une recherche
 - quand répondre directement
- Intégration de plusieurs outils (search, calculator, etc.)

Objectif : Introduire la notion d'autonomie dans les systèmes IA

Option 4 : RAG avec MCP (Très avancé)

Implémenter un système basé sur **MCP (Model Context Protocol)** :

- Structuration des échanges entre modules
- Séparation claire entre :
 - outils
 - contexte
 - modèle
- Gestion dynamique des sources de données

Objectif : Comprendre les architectures modernes et modulaires

Contraintes techniques

- Langage recommandé : **Python**
 - Bibliothèques possibles :
 - LangChain / LlamaIndex
 - Hugging Face
 - OpenAI API (optionnel)
 - Base vectorielle : FAISS, ChromaDB, Qdrant
 - Interface (optionnelle) : Streamlit, Gradio
-

Livrables attendus

Chaque groupe doit fournir :

1. **Rapport (PDF)** contenant :
 - Description du problème
 - Architecture proposée
 - Choix techniques
 - Résultats et limites
 2. **Code source** (GitHub)
 3. **Présentation orale** (10–15 min)
-

Critères d'évaluation

Critère	Pondération
Compréhension du RAG	25%

Implémentation technique	25%
Qualité des réponses	15%
Innovation options avancées	20%
Rapport & présentation	15%

Organisation

- Travail en groupes de **2 à 3 étudiants**
 - Durée : **3 à 4 semaines**
-

Bonus possibles

- Déploiement (web app)
- Utilisation GPU
- Optimisation des performances
- Dataset original (ex: domaine médical, juridique, éducatif...)